Proposition de projet — Master 2 Intelligence Artificielle

Ce que voit un détecteur de musique IA

Étudiant(e) [À compléter : nom] **Encadrant(e)** [À compléter : nom]
Durée 4 semaines **Date** 7 novembre 2026

Résumé. Les détecteurs de musique générée par IA sont quasi parfaits sur les générateurs connus, mais on ignore comment ils réagissent à un générateur inconnu, à un changement de vitesse ou à un MP3, et quelle part de leur score vient de raccourcis de jeu de données. Ce projet de réplication-extension fabrique des « faux » en ré-encodant de la musique réelle avec des codecs neuronaux (sans générateur), puis teste les détecteurs sur cinq générateurs ouverts et sous attaques.

1 Question et principe

Un détecteur appris uniquement sur de la musique réelle contre sa version ré-encodée par des codecs neuronaux généralise-t-il à des générateurs jamais vus, ou apprend-il un raccourci de jeu de données ? Et que devient-il sous changement de vitesse ou compression MP3 ?

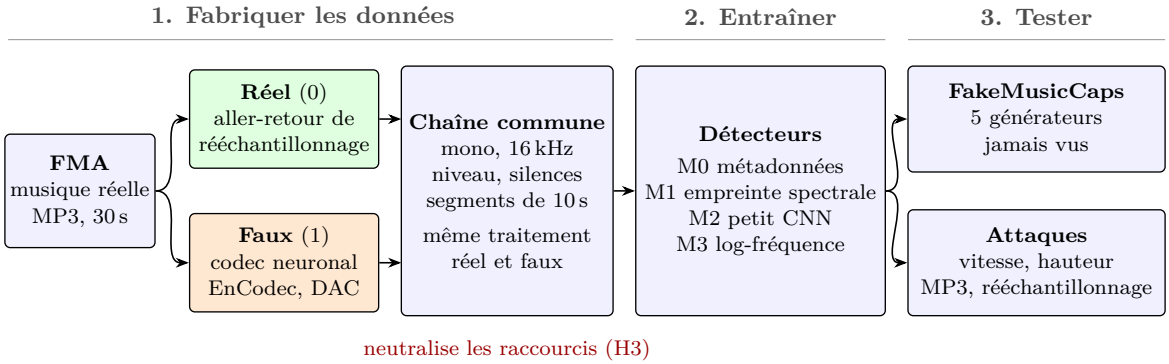


Figure 1. Principe : les « faux » viennent d'un codec, pas d'un générateur. La chaîne commune empêche de s'appuyer sur le format, la fréquence d'échantillonnage ou la durée. (0), (1) : étiquettes.

2 Positionnement

- **Afchar et al.** (Deezer, arXiv 2405.04181) distinguent le réel de sa reconstruction par auto-encodeur : scores très élevés sur les décodeurs vus, mauvaise généralisation entre familles.
- **Robustesse** (ISMIR 2026, arXiv 2607.27454) : axe log-fréquence, corrélation croisée et max-pooling résistent à la vitesse et à la hauteur ; MP3, bruit et codecs non testés.
- **FakeMusicCaps** (arXiv 2409.10684) : 27 605 extraits de 10 s, mono 16 kHz, cinq modèles ouverts. MusicDET (ICML 2026, arXiv 2605.18072) s'entraîne sans échantillon généré et s'y teste.

Apports : (1) une matrice de généralisation sur cinq générateurs, avec un « décodeur oracle » ; (2) une mesure des raccourcis par un détecteur de métadonnées seul ; (3) un test conjoint vitesse, hauteur et MP3. L'objectif est une *mesure propre* : une hypothèse réfutée reste un résultat valide.

3 Hypothèses (datées et figées avant tout entraînement)

Hypothèse	En une phrase	Réfutée si
H1 Artefacts du décodeur (Fig. 2)	Un détecteur transfère mieux vers les générateurs dont le décodeur ressemble à celui qui a fabriqué ses « faux » (décodeur oracle contre codec générique).	Pas de gain d'AUC avec l'oracle.
H2 Transfert partiel (Fig. 2)	Entraîné sur FMA contre FMA ré-encodé, le détecteur repère surtout MusicGen (basé sur EnCodec) et peu les quatre autres (AUC $< 0{,}90$).	AUC $\approx 0{,}5$ partout, ou élevée sans codec proche.
H3 Raccourcis (Fig. 1)	Une part du score vient du format, de la fréquence d'échantillonnage, du volume, de la durée ou du silence ; on la mesure par un détecteur de métadonnées *après* la chaîne commune.	AUC $\approx 0{,}5$ *et* normalisation sans effet.
H4 Log-fréquence (Fig. 3)	Le spectre linéaire s'effondre après un changement de vitesse ; la log-fréquence avec max-pooling y résiste mieux, pas forcément au MP3.	Pas mieux sous vitesse, ou aussi robuste au MP3.

Notes. MusicGen est déjà détecté dans la littérature (H2) ; sans chaîne commune, les métadonnées séparent trivialement FMA de FakeMusicCaps : 30 s MP3 contre 10 s WAV à 16 kHz (H3) ; l'article de robustesse ne teste pas le MP3 (H4).

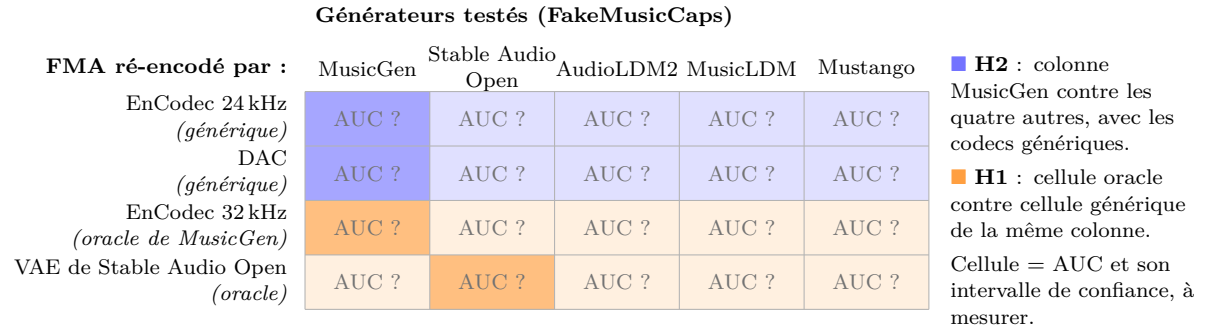


Figure 2. Carte des tests de H1 et H2 : lignes = sources d'entraînement, colonnes = générateurs testés. Schéma du plan d'analyse ; aucun résultat n'est représenté.

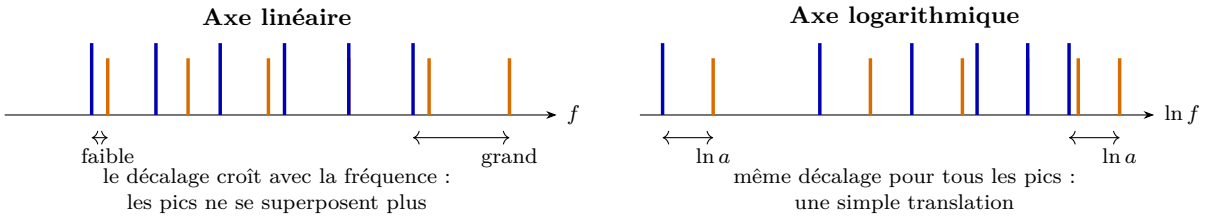


Figure 3. Pourquoi la log-fréquence aide (H4). ■ spectre original, ■ vitesse $\times a$ ($a = 1{,}25$, harmoniques 1 à 6). Une vitesse $\times a$ multiplie les fréquences : $\log(af) = \log f + \log a$. Sur l'axe logarithmique, c'est une translation, à laquelle corrélation croisée et max-pooling sont invariants.

Convention. « Mieux » : l'intervalle de confiance à 95 % de la différence d'AUC (bootstrap apparié, groupé par artiste ou par légende) exclut 0. « Transfert fort » : AUC $\geq 0{,}90$, seuil indicatif à valider avec l'encadrant.